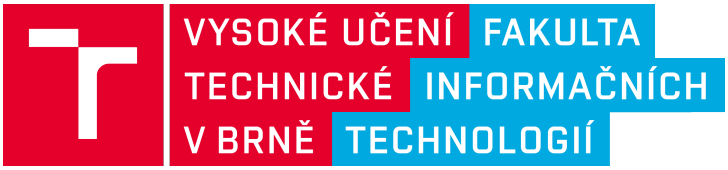

Dokumentace k projektu překladače IFJ a IAL

6. prosince 2023

Řešitelé

Jméno	Login	Rozdělení bodů
Ondřej Vala *(vedoucí)*	xvalao01	25 %
Lukáš Prokeš	xproke14	25 %
Vít Slavíček	xslavi39	25 %
Petr Štancl	xstanc12	25 %

Identifikace varianty: Tým xvalao01, varianta TRP-izp

Rozšíření

FUNEXP
OVERLOAD

Obsah

Úvod

Tento dokument stručně popisuje návrh a proces implementace překladače jazyka, který je podmnožinou jazyka Swift, do jazyka IFJcode23.

Návrh

Překladač je rozdělen do několika modulů, přičemž každý modul se specializuje na specifickou část překladu. Tato struktura umožňuje každému modulu zaměřit se na určitý aspekt překladu kódu, zatímco celkově spolupracují tak, aby pokryly všechny fáze překladu s maximální efektivitou a spolehlivostí.

Lexikální analýza

Lexikální analýzu provádí `scanner` v průběhu překladu kódu tak, jak si jiné části překladače žádají další tokeny (struktury). Celý `scanner` je založen na konečném automatu, který vidíte na obrázku 2. Ten jsme navrhli na začátku vývoje. V průběhu implementace `scanneru` jsme však zjistili, že náš návrh automatu není vždy úplně vhodný pro lexikální analýzu překládaného jazyka. `Scanner` tak provádí dodatečné operace, které nejsou obsaženy v automatu.

Jedním z problémů, kterému jsme v průběhu implementace čelili, bylo zpracování blokových komentářů. V našem návrhu automatu jsme totiž nepočítali s možností nekonečně vnořených blokových komentářů. Protože pomocí běžných konečných automatů nelze navrhnout něco jako nekončeně vnořené blokové komentáře, museli bychom například použít zásobníkový konečný automat. Abychom to vyřešili bez velkých zásahů do automatu, implementovali jsme mechanismus pomocí počítače, který sleduje počet začátečních a ukončovacích sekvencí znaků blokových komentářů.

Dalším aspektem, který jsme implementovali odlišně než pouze pomocí automatu, je rozlišení mezi identifikátory a klíčovými slovy. Konečný automat by mohl zaznamenávat rozpoznávání jednotlivých klíčových slov, ale to považujeme to za nevhodné řešení kvůli velkému počtu nových stavů a nepřehledným přechodům mezi těmito stavy. Další nevýhodou by bylo, že při přidávání dalšího klíčového slova by bylo nutné upravit část automatu a s ním i část `scanneru`. Proto jsme se rozhodli, že rozlišování mezi identifikátory a klíčovými slovy bude prováděno pomocí seznamu klíčových slov. Toto řešení je sice trochu pomalejší, ale výrazně přehlednější a jednodušší na implementaci.

Ostatní části lexikální analýzy jsou implementovány v souladu s původním návrhem automatu. Pro každý stav automatu existuje odpovídající stav ve `scanneru` a přechody jsou řešeny pomocí konstrukce switch-case. Pokud `scanner` narazí na sekvenci znaků, která není definována v konečném automatu, vrací lexikální chybu.

Syntaktická analýza

Syntaktickou analýzu celého překládaného kódu zajišťuje `parser`. Výjimkou jsou výrazy, u kterých se o precedenční syntaktickou analýzu stará `expression parser`.

Rekurzivní sestup

Při spuštění programu je aktivován `parser`, který postupně zpracovává tokeny poskytované scannerem a provádí syntaktickou analýzu. Implementace parseru je založena na jednoprůchodovém rekurzivním sestupu a pracuje s LL1 gramatikou. Jedinou výjimkou je čtení argumentů funkce, kde bylo obtížné jednoznačně určit, zda se jedná o argument, či o jméno argumentu. `Parser` pracuje dokud nenačte operátor přiřazení, nebo nenarazí na jiné místo, kde je potřeba vyřešit výraz (argument funkce, návratová hodnota z funkce). V tom případě volá funkci z modulu `expression parser` a přes frontu ve struktuře `programState` ji předá už načtené tokeny.

Po vyřešení výrazu `expression parser` vrátí přes `programState` adresu výsledku, datový typ výsledku a další parametry. Následně `parser` provede sémantické kontroly jestli má výsledek očekávaný typ. V případě, že `parser` narazí na sekvenci tokenů, pro kterou nemá pravidlo z gramatiky, vrátí syntaktickou chybu a ukončí překlad.

Precedenční syntaktická analýza

`Expression parser` žádá od `scanneru` tokeny tak dlouho, dokud nenarazí na token, který není schopen zpracovat, nebo dokud nenarazí na specifickou sekvenci tokenů označující konec výrazu. Načtené tokeny jsou ukládány `expression parserem` do fronty. Kromě toho `expression parser` využívá zásobník pro průběžné zpracování výrazu.

Průběh analýzy začíná vyhodnocením precedence tokenu na vrcholu zásobníku a tokenu na začátku fronty podle precedenční tabulky 1. Pokud je na vrcholu fronty token s vyšší prioritou, je přesunut na vrchol zásobníku a program pokračuje ve zpracování dalších tokenů. Pokud je na vrcholu zásobníku token s nižší prioritou, použije se vhodné redukční pravidlo 4.3, které buď sníží počet tokenů na zásobníku, nebo je transformuje na jiný typ. Tento postup se opakuje, dokud na vrcholu zásobníku není pouze token s výsledkem a vstupní fronta není prázdná. Výsledný token je pak vrácen `parseru`, který jej dále zpracuje. Vyjimku tvoří funkce ve výrazech. V tomto případě `expression parser` volá funkci z `parseru`, která se stará o zpracování funkcí.

Syntaktická chyba nastává v případě, kdy se snažíme najít precedenci dvou tokenů, které nesmějí následovat za sebou, nebo pokud není nalezeno vhodné redukční pravidlo.

Sémantická analýza

Sémantická analýza probíhá souběžně se syntaktickou analýzou během generování kódu. O kontrolu sémantiky se starají tři hlavní komponenty: `parser`, `expression parser` a `symtable` (tabulka symbolů). `Parser` zajišťuje kontrolu typů při použití operátorů přiřazení. `Expression parser` sleduje správné použití typů operandů ve výrazech. `Symtable` pak provádí sémantické kontroly související s funkcemi. Tato tabulka uchovává všechna volání funkcí v seznamu a na konci překladu provede sémantickou kontrolu všech těchto volání funkcí.

Generování cílového kódu

O generování cílového kódu se stará `symtable`. Generovaný kód je během překladu ukládán do 4 seznamů, které obsahují:

1. definice a těla funkcí
2. hlavní funkci
3. reference pro komunikaci mezi `parserem` a `expression parserem`
4. temporary list - deklarace proměnných před smyčkami

Na závěr běhu programu projde `generátor` všechny seznamy a sestaví výsledný kód. Každá položka v seznamu představuje jeden řádek kódu. Pro vznik validní a funkčního je klíčové, aby seznamy následovaly ve správném pořadí.

Datové struktury

Při implementaci jsme využili několik klíčových datových struktur. Zde popíšeme nejdůležitější z nich:

- `struct token`: Reprezentuje jednotlivé tokeny a slouží ke komunikaci mezi scannerem a parserem. Také se pomocí tokenů provádí precedenční syntaktická analýza.

- `struct programState`: Slouží k propojení informací mezi různými funkcemi programu. Výhodou této struktury je, že sdružuje všechny potřebné informace do jednoho objektu. Pokud bylo potřeba při implementaci přidat další informaci, stačilo přidat novou položku do této struktury a nemusely se upravovat všechny funkce, které tuto strukturu využívají. Díky této struktruře by bylo v případě potřeby snadné doimplementovat další možná rozšíření.
- `struct symtable`: Představuje tabulku symbolů a je implementována jako seznam hašovacích tabulek. Každý prvek seznamu reprezentuje jedno zanoření. Pro hašování používáme funkci `MurmurOAAT()`[1].
- `struct generator`: Slouží k průběžnému ukládání generovaného cílového kódu. Obsahuje čtyři seznamy, kde každý řádek představuje jeden řádek v cílovém kódu. Dále obsahuje hašovací tabulku pro ukládání adres funkcí ve vygenerovaném kódu, což je implementováno pro podporu přetěžování funkcí.

Členění implementačního řešení

`scanner.c`	lexikální analýza
`parser.c`	implementace metody rekurzivního sestupu
`expression_parser.c`	implementace precedenční syntaktické analýzy
`symtable.c`	implementace hašovací tabulky s implicitním zřetězením položek
`generator.c`	generování výsledného kódu

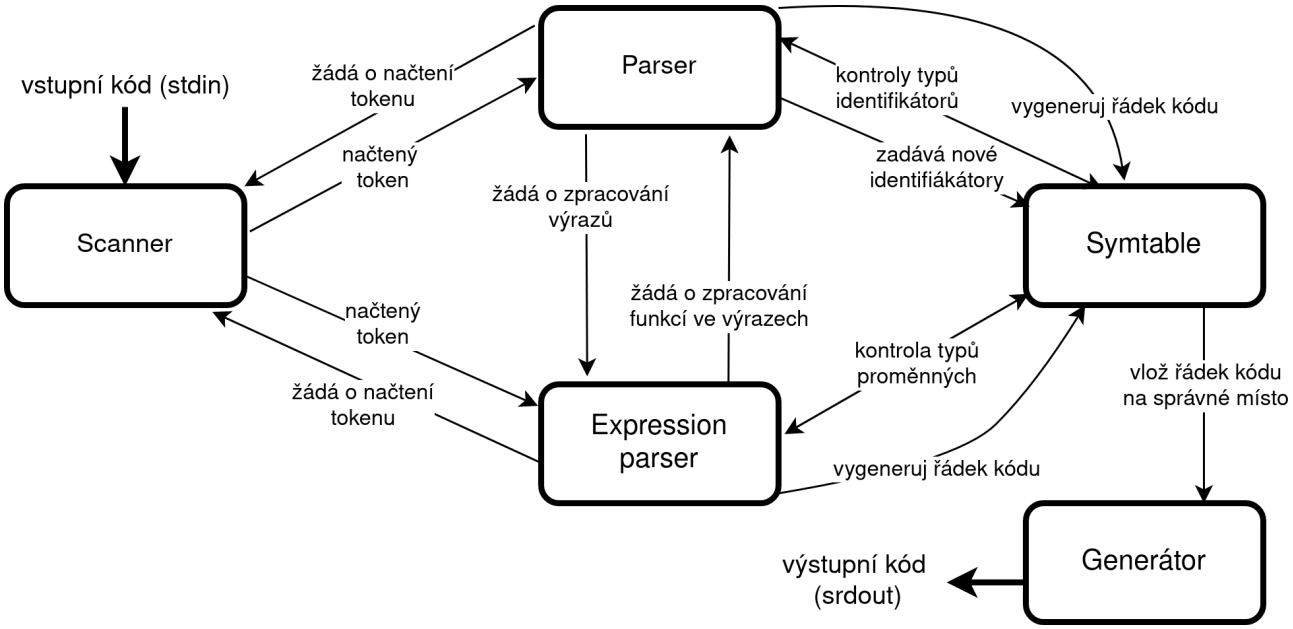

Obrázek 1: Diagram komunikace jednotlivých částí překladače

Implementace

Vývoj překladače probíhal během celého semestru. Snažili jsme se udržovat konstantní tempo práce, což se nám podařilo alespoň částečně. Pro správu verzí a sledování vývoje jsme využívali verzovací

[1] `https://github.com/aappleby/smhasher/blob/master/src/Hashes.cpp`

systém Git se sdíleným repositářem na GitHubu. Hlavním komunikačním kanálem byl Discord, kde jsme také pořádali online porady.

V počáteční fázi testování jsme využívali framework Google Test. Avšak v průběhu vývoje jsme zjistili, že pro naše účely je nevyhovující. Náš kód musel být i kompatibilní s překladačem do jazyka C++. Proto jsme vytvořili vlastní skript v jazyce bash, který spouštěl překladač a porovnával jeho výstupy s referenčními výsledky. Tímto způsobem jsme dosáhli efektivního a přizpůsobitelného testování na míru našim potřebám.

Rozdělení práce

- **Ondřej Vala**
  - vedoucí týmu
  - návrh precedenční tabulky a precedenčních pravidel
  - návrh lexikálního analyzátoru
  - implementace expression parseru
- **Lukáš Prokeš**
  - návrh lexikálního analyzátoru
  - návrh LL gramatiky
  - implementace parseru
  - vedoucí testování
- **Vít Slavíček**
  - implementace tabulky symbolů
  - implementace generátoru
  - generické datové struktury
- **Petr Štancl**
  - implementace scanneru
  - vytvoření pomocné knihovny na práci s řetězci

Přílohy

Konečný automat

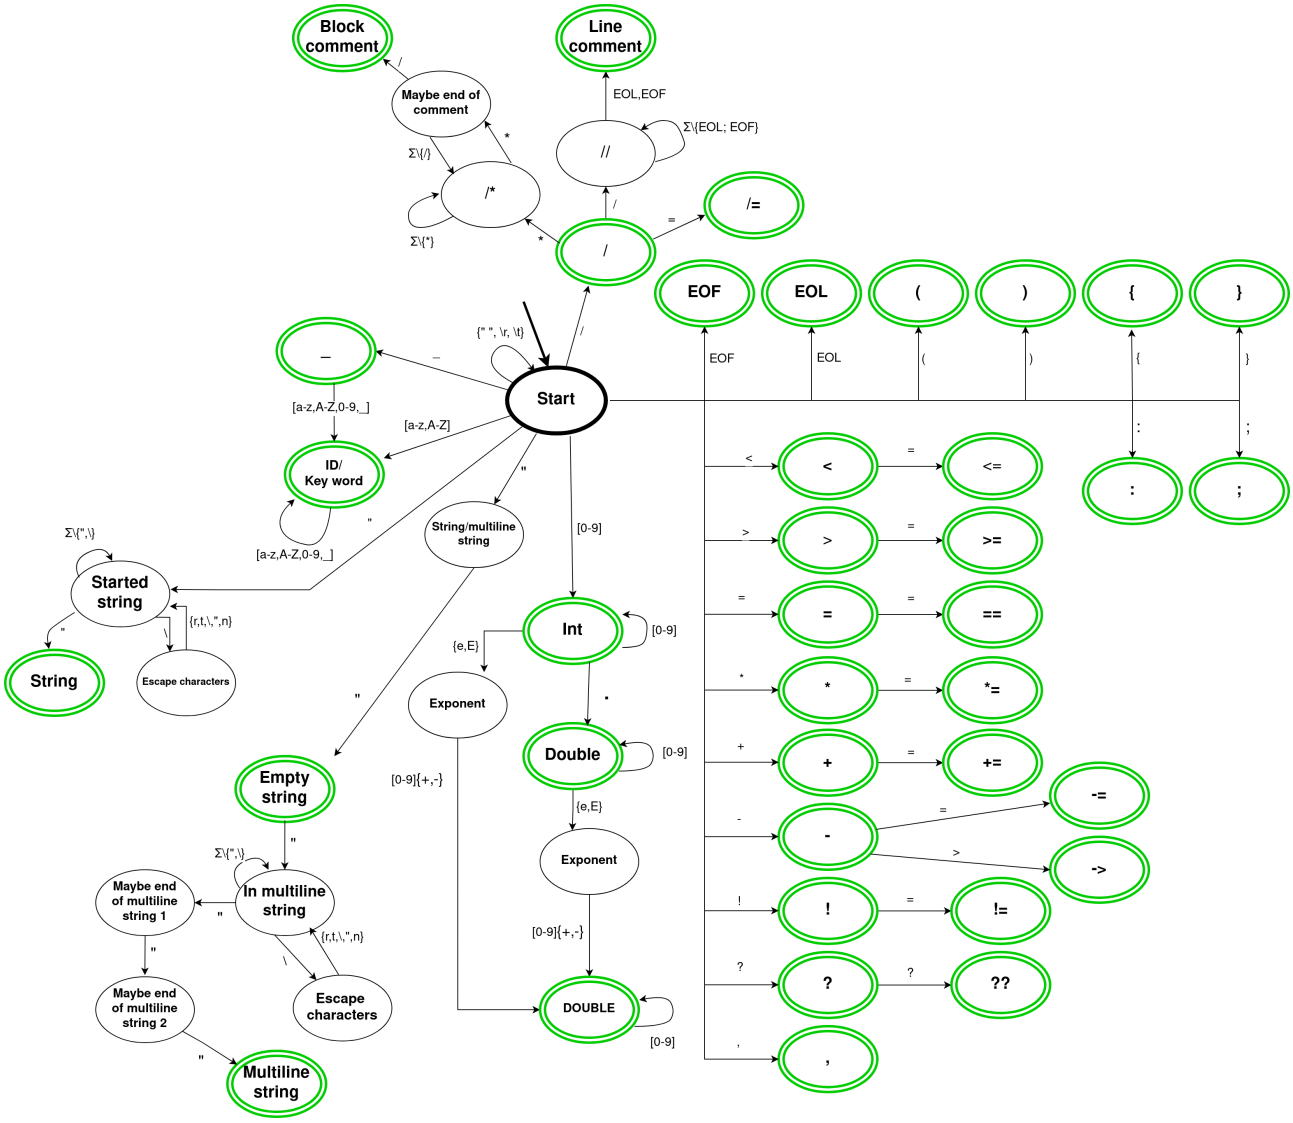

Obrázek 2: Konečný automat lexikálního analyzátoru

Precedenční tabulka

	(	)	* /	+ -	< <= > >=	== !=	??	!	i	$
(	<	=	<	<	<	<	<	>	<	
)		>	>	>	>	>	>	>		>
* /	<	>	>	>	>	>	>	<	<	>
+ -	<	>	<	>	>	>	>	<	<	>
< <= > >=	<	>	<	<	>	>	>	<	<	>
== !=	<	>	<	<	>	>	>	<	<	>
??	<	>	<	<	>	<	<	<	<	>
!	>	>	>	>	>	>	>	>	>	>
i		>	>	>	>	>	>	>		>
$	<		<	<	<	<	<	<	<	

Tabulka 1: Precedenční tabulka

Redukční pravidla

1. $E \to (E)$
2. $E \to E * E$
3. $E \to E / E$
4. $E \to E + E$
5. $E \to E - E$
6. $E \to E > E$
7. $E \to E >= E$
8. $E \to E < E$
9. $E \to E <= E$
10. $E \to E == E$
11. $E \to E != E$
12. $E \to E \; ?? \; E$
13. $E \to E!$
14. $E \to i$

Redukční pravidla pro analýzu výrazu

LL-gramatika

1. <start> → <eol> <code>
2. <start> → EPS
3. <code> → <definition> EOL <code>
4. <code> → <statement> EOL <code>
5. <code> → EOF
6. <eol> → EOL
7. <eol> → EPS
8. <type> → Int
9. <type> → Double
10. <type> → String
11. <definition> → func <eol> ID <eol> (<functionParams>) <eol> <funcDefMid>
12. <funcDefMid> → {<statements>}
13. <funcDefMid> → -> <eol> <type> <eol> {<statements>}
14. <functionParams> → EPS
15. <functionParams> → EOL <functionParams>
16. <functionParams> → <functionParam> <functionParamsN> <eol>
17. <functionParamsN> → , <eol> <functionParam> <functionParamsN>
18. <functionParamsN> → EPS
19. <functionParam> → _<eol> ID <eol> : <eol> <type> <eol>
20. <functionParam> → ID <eol> ID <eol> : <eol> <type> <eol>
22. <statements> → <eol> <statementsBlock> <eol>
23. <statements> → EPS
24. <statementsBlock> → <statement> EOL <statementsBlock>
25. <statementsBlock> → EPS
26. <statement> → <varDec>
27. <statement> → if <eol> <letExp> <eol> {<statements>} <eol> else <eol> {<statements>}
28. <statement> → while <eol> <letExp> <eol> {<statements>}
29. <statement> → return <returnExpression>
30. <statement> → ID <callOrAssign>
66. <statement> → <parseBuildInFunctions>
68. <letExp> → let <eol> ID
69. <letExp> → <expression>
36. <callOrAssign> → <eol> <assign>
37. <callOrAssign> → (<arguments>)
61. <assign> → = <expression>
62. <assign> → += <expression>
63. <assign> → -= <expression>

64. <assign> → *= <expression>
65. <assign> → /= <expression>
38. <varDec> → let <eol> ID <eol> <varDecMid>
39. <varDec> → var <eol> ID <eol> <varDecMid>
40. <varDecMid> → : <eol> <type> <eol> <varDef>
41. <varDecMid> → = <expression>
42. <varDef> → EPS
43. <varDef> → = <expression>
44. <returnExpression> → <expression>
45. <returnExpression> → EPS
46. <arguments> → EPS
47. <arguments> → EOL <arguments>
48. <arguments> → <argument> <argumentsN> <eol>
49. <argumentsN> → , <eol> <argument> <argumentsN>
50. <argumentsN> → EPS
51. <argument> → <expression>
52. <argument> → ID <eol> <argWithName> <eol>
53. <argWithName> → : <eol> <expression>
54. <argWithName> → EPS
60. <expression> → SEND TO EXPRESSION PARSER
67. <expression> → KW_READSTRING
70. <expression> → KW_READINT
71. <expression> → KW_READDOUBLE
72. <expression> → KW_INT_TO_DOUBLE
73. <expression> → KW_DOUBLE_TO_INT
74. <expression> → KW_LENGTH
75. <expression> → KW_SUBSTRING
76. <expression> → KW_ORD
77. <expression> → KW_CHR

LL-tabulka

	ID	IntData	Double Data	String Data	func	return	if	else	while	let	var	Int	Double	String	(	)	{	}	=	+=	-=	*=	/=	->	:	_	,	EOL	EOF	$	<exp>
<start>	1				1	1	1		1	1	1																1	1	2	
<code>	4				3	4	4		4	4	4																	5		
<eol>	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7					7	7	7	6	7		
<type>												8	9	10																
<definition>					11																									
<funcDefMid>																	12						13							
<functionParams>	16														14										16		15			
<functionParamsN>																18										19	17	18			
<functionParam>	20																													
<statements>	22					22	22		22	22	22							23									22			
<statementsBlock>	24					24	24		24	24	24							25									25			
<statement>	30					29	27		28	26	26																			
<letExp>										68																				69
<callOrAssign>														37				36	36	36	36	36					36			
<assign>																		61	62	63	64	65								
<varDec>										38	39																			
<varDecMid>																		41						40						
<varDef>																		42	43								42			
<returnExpression>																	45										45			44
<arguments>	48	48	48	48											46	50											47			
<argumentsN>																										49	50			
<argument>	52	51	51	51																										
<argWithName>															54									53			54	54		
<expression>																														

Obrázek 3: LL-tabulka